

Sveučilište Jurja Dobrile u Puli
Fakultet informatike u Puli

MODELIRANJE I SIMULACIJE

Projektni zadatak

Monte Carlo simulacija strategija kladjenja u briškula-based igri na sreću

Kolegij: Modeliranje i simulacije

Mentor: dr.sc. Robert Sajina, asistent

Programski jezik: R (verzija ≥ 4.0)

Vrsta simulacije: Monte Carlo (stohastička diskretna simulacija)

Akadska godina: 2025./2026.

Datum: Pula, 2026.



Contents

1	Opis sustava i područje primjene	3
1.1	Uvod	3
1.2	Opis igre i pravila modela	3
1.3	Područje primjene	3
2	Vrsta primijenjene simulacije i simulacijski jezik	4
2.1	Vrsta simulacije	4
2.2	Simulacijski jezik i okruženje	4
3	Opis prikupljenih podataka — izbor varijabli i distribucija	5
3.1	Ulazne varijable modela	5
3.2	Ključna slučajna varijabla i njezina distribucija	5
3.2.1	Parametri hipergeometrijske distribucije	6
3.3	Izvedene varijable	6
4	Konceptualni model	7
4.1	Opis konceptualnog modela	7
4.2	Strategije kladenja	8
5	Računalni model	10
5.1	Arhitektura koda	10
5.2	Funkcija jedne runde	10
5.3	Monte Carlo simulator strategija	11
6	Opis simulacije, tumačenje rezultata i preporuke	12
6.1	Tijek simulacije	12
6.2	Teorijski RTP i house edge	12
6.3	Statistička validacija modela	13
6.4	Analiza preživljavanja — usporedna statistika	13
6.5	Analiza strategija	13
6.5.1	Flat bet strategija	13
6.5.2	Martingale strategija	13
6.5.3	Anti-Martingale strategija	14
6.5.4	Kelly kriterij	14
6.5.5	Usporedna tablica karakteristika	14
6.6	Analiza ograničenog vremenskog horizonta	14
6.7	Analiza ekstremnih događaja	14
6.8	Casino optimizacija — preporuke upravi	15
6.9	Casino risk management — stress test	16
7	Zaključak	17
8	Popis literature	18

A	Potpuni programski kod	19
A.1	Inicijalizacija i parametri sustava	19
A.2	Logika modela	19
A.3	Simulacija strategija	20
A.4	Analiza, validacija i casino optimizacija	20

1. Opis sustava i područje primjene

1.1. Uvod

Kartaška igra Briškula (tal. *Briscola*) jedna je od najrasprostranjenijih tradicijskih igara na Mediteranu, posebno popularna u Italiji i duž istočne jadranske obale. U kontekstu modeliranja i simulacija, Briškula predstavlja idealan predmet proučavanja jer kombinira elemente stohastičnosti (slučajno miješanje i izvlačenje karata) s determinističkim sustavom bodovanja, što omogućuje preciznu matematičku analizu i verifikaciju modela.

Ovaj projekt modelira jednostavnu varijantu igre u kojoj jedan igrač ulaže novac svaki krug, a konačni ishod ovisi o broju izvučenih adutnih karata (briškula/aduta). Sustav je opisan kao **stohastički proces uzorkovanja bez ponavljanja** iz konačne populacije karata jer se jednom izvučena karta ne vraća u špil.

1.2. Opis igre i pravila modela

Špil se sastoji od $N = 40$ karata podijeljenih ravnomjerno u $S = 4$ boje (vrste), pri čemu svaka boja sadrži $K = 10$ karata. Na početku svake runde odvija se sljedeći slijed događaja:

1. Nasumično se bira jedna od četiri boje kao adut (briškola).
2. Špil se nasumično izmiješa — simulacija fizičkog miješanja karata.
3. Igrač izvlači $n = 10$ karata bez ponavljanja (uzorkovanje bez povrata).
4. Broji se broj pogodaka X — karata koje pripadaju adutnoj boji.
5. Na temelju X izračunava se bodovni rezultat, isplatni faktor i neto profit.

Bodovni sustav temelji se na linearnoj transformaciji broja aduta: svaki pogodak donosi +10 bodova, a svaki promašaj nosi penalizaciju od −10 bodova. Početni prag iznosi $P_0 = 120$ bodova, što odgovara situaciji break-even (bez dobitka ni gubitka).

1.3. Područje primjene

Model ima dvostruku primjenu:

- **Perspektiva igrača:** Analiza dugoročnih strategija kladenja i upravljanja kapitalom (*bankroll management*) — koja strategija maksimizira šansu preživljavanja i profita pri visokom house edgeu?
- **Perspektiva casina/kockarnice:** Optimizacija limita rundi i procjena maksimalne financijske izloženosti pri različitim strategijama igrača (*risk management*). Rezultati su primjenjivi za donošenje poslovnih odluka o limitima stola i strukturi sesija.

Rezultati su primjenjivi u teoriji igara, operacijskim istraživanjima, financijskom modeliranju te obrazovnoj demonstraciji stohastičkih procesa.

2. Vrsta primijenjene simulacije i simulacijski jezik

2.1. Vrsta simulacije

Primijenjena metoda je **Monte Carlo simulacija** — klasa stohastičkih računalnih metoda koja koristi ponavljano nasumično uzorkovanje za dobivanje numeričkih rješenja problema koji bi analitički bili teško ili nemoguće rješivi. Ova vrsta simulacije spada u kategoriju **diskretnih stohastičkih simulacija** jer:

- Sustav mijenja stanje u diskretnim vremenskim koracima (runde igre).
- Slučajne varijable poprimaju diskretne vrijednosti ($X \in \{0, 1, \dots, 10\}$).
- Ne postoji kontinuirani tok vremena — svaka runda je neovisni stohastički eksperiment.
- Distribucija ishoda procjenjuje se empirijski iz velikog broja ponavljanja ($N = 50\,000$ rundi).

Za razliku od analitičkih metoda koje zahtijevaju poznavanje zatvorene forme rješenja, Monte Carlo metoda omogućuje procjenu distribucije bankrolla, vjerojatnosti bankrota i očekivane zarade casina za svaku od četiri strategije klađenja.

2.2. Simulacijski jezik i okruženje

Table 2.1: Okruženje simulacije i ključni parametri implementacije.

Parametar	Vrijednost
Programski jezik	R (verzija ≥ 4.0)
IDE / Notebook	RStudio / Jupyter Notebook (IRkernel)
Reproduktivnost	<code>set.seed(42)</code> — fiksirani pseudoslučajni seed
Ključne funkcije	<code>sample()</code> , <code>replicate()</code> , <code>dhyper()</code> , <code>chisq.test()</code>
Vizualizacija	Base R Graphics + ggplot2 (Shiny aplikacija)
Broj simuliranih rundi	50 000 po strategiji
Broj replikacija (optim.)	500 po koraku analize

Odabir programskog jezika R opravdan je njegovom izvrsnom podrškom za statističke distribucije (uključujući hipergeometrijsku), vektorske operacije i reproduktivnost rezultata putem fiksiranog seeda.

3. Opis prikupljenih podataka — izbor varijabli i distribucija

3.1. Ulazne varijable modela

Sve ulazne veličine definirane su analitički na temelju pravila igre i nisu prikupljene empirijskim putem, što je karakteristično za formalne igre s poznatim pravilima.

Table 3.1: Globalni parametri simulacijskog modela.

Simbol	Naziv	Vrijednost	Opis
N	Veličina špila	40	Ukupan broj karata u špilu
S	Broj boja	4	Familije karata
K	Karata po boji	10	Karata svake familije
n	Broj izvučenih karata	10	Veličina ruke igrača po rundi
P_0	Početni bodovi	120	Bazni bodovni rezultat (break-even prag)
B_0	Početni bankroll	100 000 €	Početni kapital igrača
b_{flat}	Osnovni ulog	10 €	Ulog za Flat / početni za Mart./Anti-Mart.
f	Kelly frakcija	0.05 (5%)	Udio bankrolla koji Kelly strategija ulaže
b_{max}	Maksimalni ulog	500 €	Gornji limit uloga (simulira limit stola)
N_{SIMS}	Broj rundi	50 000	Iteracije Monte Carlo simulacije

3.2. Ključna slučajna varijabla i njezina distribucija

Centralna slučajna varijabla modela je broj adutnih karata u ruci igrača. Ova varijabla slijedi **hipergeometrijsku distribuciju** jer se izvlačenje karata provodi bez povrata iz konačnog špila:

$$X \sim \text{Hyper}(N = 40, K = 10, n = 10)$$

Vjerojatnost da igrač izvuče točno x adutnih karata:

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}} = \frac{\binom{10}{x} \binom{30}{10-x}}{\binom{40}{10}}, \quad x \in \{0, 1, \dots, 10\}$$

3.2.1. Parametri hipergeometrijske distribucije

Table 3.2: Parametri hipergeometrijske distribucije $X \sim \text{Hyper}(40, 10, 10)$.

Parametar	Formula	Vrijednost	Interpretacija
Očekivanje $\mathbb{E}[X]$	$n \cdot \frac{K}{N}$	2.5	Prosječno 2.5 aduta po rundi
Varijanca $\text{Var}(X)$	$n \cdot \frac{K}{N} \cdot \frac{N-K}{N} \cdot \frac{N-n}{N-1}$	≈ 1.442	Standardna devijacija $\sigma \approx 1.20$
Mod distribucije	$\lfloor \frac{(n+1)(K+1)}{N+2} \rfloor$	2 ili 3	Najčešći ishod: 2 ili 3 aduta

Očekivana vrijednost $\mathbb{E}[X] = 2.5$ sugerira da će igrač u prosjeku imati između 2 i 3 aduta po dijeljenju. Varijanca od 1.442 ($\sigma \approx 1.2$) ukazuje na relativno nisku volatilnost — ekstremni rezultati (0 ili 8+ aduta) su statistički rijetki.

3.3. Izvedene varijable

- **Bodovni rezultat:**

$$\text{pts} = P_0 + X \cdot 10 - (n - X) \cdot 10 = 120 + X \cdot 10 - (10 - X) \cdot 10$$

- **Isplatni faktor:**

$$\text{mult} = \frac{\text{pts}}{P_0}$$

Ako $\text{mult} = 1$, runda je break-even; $\text{mult} > 1$ znači dobitak.

- **Neto profit po rundi:**

$$\text{profit} = (\text{mult} - 1) \cdot \text{bet}$$

- **Bankroll (kumulativno):**

$$B_{i+1} = B_i + \text{profit}_i$$

4. Konceptualni model

4.1. Opis konceptualnog modela

Konceptualni model opisuje logiku i tok simulacije na razini apstrakcije, neovisno o implementaciji. Sustav se može promatrati kao **ciklički stohastički automat** s konačnim brojem stanja. Svaka runda prolazi kroz isti redoslijed koraka, a simulacija završava kada igrač ostane bez novca (bankrot) ili kada se dosegne zadani broj rundi.




Figure 4.1: Dijagram toka konceptualnog modela Monte Carlo simulacije.

4.2. Strategije kladjenja

Model implementira četiri strategije upravljanja kapitalom:

Table 4.1: Pregled implementiranih strategija kladenja.

Strategija	Opis	Formula uloga	Karakteristika
Flat bet	Ulog je uvijek fiksni	$b = b_{flat}$	Niska volatilnost, jednostavna
Martingale	Udvostručuje ulog nakon gubitka	$b_{i+1} = \min(2b_i, b_{max})$ ako gubitak, inače b_{flat}	Visoki rizik, brz bankrot
Anti-Martingale	Udvostručuje ulog nakon dobitka	$b_{i+1} = \min(2b_i, b_{max})$ ako dobitak, inače b_{flat}	Juri serije, nestabilna
Kelly kriterij	Fiksni postotak bankrolla	$b_i = \max(1, f \cdot B_i)$, $f = 0.05$	Teorijski optimalna za preživljavanje

5. Računalni model

5.1. Arhitektura koda

Računalni model podijeljen je u modularne blokove koji odgovaraju fazama simulacije:

Table 5.1: Arhitektura koda — moduli simulacije.

Blok	Naziv	Ključna funkcija	Opis
1	Inicijalizacija	<code>set.seed(42)</code>	Globalni parametri, fiksiranje pseudoslučajnosti
2	Logika igre	<code>play_round(bet)</code>	Simulacija jedne runde
3	Strategije	<code>simulate_strategy(...)</code>	Monte Carlo petlja za sve strategije
4	Izvršavanje	<code>lapply(strategies, ...)</code>	Pokretanje i pohrana rezultata
5	Tablični ispis	<code>data.frame(...)</code>	Pregled prvih 10 rundi, detekcija bankrota
6	Validacija	<code>dhyper()</code> , <code>chisq.test()</code>	Simulacija vs. teorijska distribucija
7	Ekstremni događaji	<code>choose()</code> , <code>dhyper()</code>	Analiza vjerojatnosti crnog labuda
8	Zbirna statistika	<code>sapply(...)</code>	Preživljavanje, konačni bankroll
9	Limit analiza	<code>simulate_strategy(n=1000)</code>	Mod ograničenog horizonta
10	Casino optimizacija	<code>replicate(500, ...)</code>	Prosječna zarada casina po broju rundi
11	Risk management	<code>analyze_casino_risk()</code>	Stress test: maks. izloženost

5.2. Funkcija jedne runde

Centralna funkcija simulacije je `play_round(bet)` koja implementira stohastički proces jedne runde igre. Koristi diskretnu uniformnu distribuciju za odabir aduta i uzorkovanje bez ponavljanja za simulaciju fizičkog špila:

Listing 5.1: Implementacija funkcije `play_round()` u R-u.

```
1 # Odabir aduta: diskretna uniformna distribucija na {1, 2, 3, 4}
2 briscola_suit <- sample(1:SUITS, 1)
3
4 # Mijesanje spila: nasumična permutacija 40 karata
5 shuffled <- sample(deck_suits)
6
7 # Izvlačenje prvih 10 karata (uzorkovanje bez ponavljanja)
8 hand <- shuffled[1:N_CARDS_DRAWN]
9
10 # Izracun pogodaka, bodova i profita
11 hits <- sum(hand == briscola_suit)
12 misses <- N_CARDS_DRAWN - hits
13 pts <- INIT_PTS + hits * 10 - misses * 10
```

```

14 mult    <- pts / INIT_PTS
15 profit  <- (mult - 1) * bet
16
17 return(list(hits = hits, profit = profit, mult = mult))

```

5.3. Monte Carlo simulator strategija

Funkcija `simulate_strategy()` implementira iterativnu Monte Carlo petlju koja simulira $N_{SIMS} = 50\,000$ rundi za odabranu strategiju:

Listing 5.2: Iterativni Monte Carlo simulator (isječak).

```

1 for (i in seq_len(n_sims)) {
2   # Odabir uloga prema strategiji
3   bet <- switch(strategy_name,
4     "Flat"           = flat_bet,
5     "Martingale"     = current_bet,
6     "Anti-Martingale" = current_bet,
7     "Kelly"          = max(1, bankroll[i] * KELLY_FRACTION)
8   )
9   bet <- min(bet, bankroll[i]) # Ne može uložiti više nego što ima
10
11   if (bankroll[i] <= 0) {      # Prijevremeni izlaz pri bankrotu
12     bankroll[(i+1):(n_sims+1)] <- 0
13     break
14   }
15
16   res <- play_round(bet)
17   bankroll[i+1] <- bankroll[i] + res$profit
18
19   # Azuriranje uloga za progresivne strategije
20   if (strategy_name == "Martingale") {
21     current_bet <- if (res$profit < 0)
22       min(current_bet * 2, MAX_BET) else flat_bet
23   } else if (strategy_name == "Anti-Martingale") {
24     current_bet <- if (res$profit > 0)
25       min(current_bet * 2, MAX_BET) else flat_bet
26   }
27 }

```

6. Opis simulacije, tumačenje rezultata i preporuke

6.1. Tijek simulacije

Simulacija se provodi u sljedećim sekvencijalnim fazama:

1. **Inicijalizacija** — postavljanje seeda (42), globalnih varijabli, špila karata i svih parametara strategija.
2. **Izvođenje strategija** — svaka od četiri strategije pokreće se kroz 50 000 iteracija. Ukupno je simulirano 200 000 rundi igre.
3. **Tablični ispis** — prikaz prvih 10 rundi svake strategije s ulogom, pogocima, neto rezultatom i ishodom.
4. **Statistička validacija** — usporedba simulirane distribucije s teorijskom hipergeometrijskom; formalni χ^2 test.
5. **Analiza ekstremnih događaja** — procjena vjerojatnosti statistički “crnog labuda”.
6. **Analiza limita rundi** — ishod kratke sesije od $N = 20$ rundi.
7. **Casino optimizacija** — Monte Carlo analiza s 500 replikacija $\times$ 10 koraka.
8. **Casino risk management** — stress test Martingale strategije.

6.2. Teorijski RTP i house edge

Ključni analitički rezultat modela je teorijski **Return to Player (RTP)**:

$$\mathbb{E}[\text{mult}] = \frac{P_0 + \mathbb{E}[X] \cdot 10 - (n - \mathbb{E}[X]) \cdot 10}{P_0} = \frac{120 + 25 - 75}{120} = \frac{70}{120} \approx 0.5833$$

Table 6.1: Teorijski RTP i house edge.

Metrika	Vrijednost	Interpretacija
Teorijski RTP	58.33%	Igrač vraća 58.33 centi na svaki uloženi euro
House Edge	41.67%	Casino zadržava 41.67 centi na svaki uloženi euro
Break-even X	$X = 5$	5 aduta = 120 bodova = mult= 1
Prosječni X	$X = 2.5$	Daleko ispod break-even praga od 5 aduta

Visoki house edge od 41.67% znači da je igra matematički **izrazito nepovoljna za igrača**. Neovisno o odabranoj strategiji, igrač ne može dugoročno biti profitabilan.

6.3. Statistička validacija modela

Validacija se provodi usporedbom simulirane frekvencije pogodaka aduta s teorijskom hipergeometrijskom distribucijom:

Listing 6.1: Statistička validacija: χ^2 test.

```

1 # Teorijske vjerojatnosti
2 theory <- dhyper(0:10, K=10, NmK=30, n=10)
3
4 # Simulirane frekvencije (iz 50 000 rundi Flat strategije)
5 h_counts <- table(factor(results$Flat$hits, levels=0:10))
6 h_dist <- h_counts / sum(h_counts)
7
8 # Formalni chi-kvadrat test
9 chisq.test(h_counts, p = theory)
```

Rezultat χ^2 testa potvrđuje da između simulirane i teorijske distribucije nema statistički značajne razlike ($p \gg 0.05$), čime se verificira ispravnost implementacije.

6.4. Analiza preživljavanja — usporedna statistika

Table 6.2: Usporedna statistika preživljavanja — 50 000 rundi, bankroll 100 000 €.

Strategija	Runde do bankrota	Status	Konačni bankroll
Flat	1 255	BANKROTIRAO	0 €
Martingale	1 243	BANKROTIRAO	0 €
Anti-Martingale	1 234	BANKROTIRAO	0 €
Kelly	1 222	BANKROTIRAO	0 €

Sva četiri igrača bankrotiraju. Ključna razlika je u **brzini bankrota**: Flat strategija preživljava najdulje (1 255 rundi), dok Kelly paradoksalno bankrotira najbrže (1 222 runde) usprkos teorijskoj optimalnosti.

6.5. Analiza strategija

6.5.1. Flat bet strategija

Flat bet pruža najstabilniji i najsporiji pad bankrolla. Budući da se ulog ne mijenja adaptivno, gubici su ograničeni i predvidivi. Igrač preživljava 1 255 rundi — najdulje od svih četiri strategija. Flat bet je optimalan izbor za igrača koji želi maksimizirati broj odigranih rundi uz minimizaciju volatilnosti.

6.5.2. Martingale strategija

Martingale u teoriji “garantira” povrat nakon dovoljno dugog niza, ali u praksi nailazi na dva ključna ograničenja: (1) eksponencijalni rast uloga brzo dostiže gornji limit $b_{max} = 500$ €, te (2) jedan duži niz gubitaka uzrokuje brz i trajan bankrot. S perspektive casina, ovo je **najisplativija strategija**.

6.5.3. Anti-Martingale strategija

Udvostručivanjem uloga nakon dobitka, igrač “juri” serije dobitaka. Strategija je profitabilna pri kratkim sretnim serijama, ali nestabilna na dugom roku. Bankrot nastupa u 1 234. rundi — između Flat i Martingale po trajanju preživljavanja.

6.5.4. Kelly kriterij

Kelly strategija, teoretski optimalna za dugoročno preživljavanje u *pozitivnim* igrama, ovdje daje spori ali stabilan pad jer ulaže samo 5% trenutnog bankrolla. Nikada ne gubi sve odjednom, ali zbog negativnog očekivanja (RTP 58.33%) konvergira prema nuli. Bankrot u 1 222. rundi — paradoksalno najbrži.

6.5.5. Usporedna tablica karakteristika

Table 6.3: Usporedna analiza strategija.

Karakteristika	Flat	Martingale	Anti-Mart.	Kelly
Volatilnost bankrolla	Niska	Visoka	Umjerena	Niska
Rizik bankrota	Srednji	Visok	Srednji	Nizak*
Runde do bankrota	1 255	1 243	1 234	1 222
Korist za casino	Umjerena	Visoka	Umjerena	Niska
Kompleksnost	Trivijalna	Jednostavna	Jednostavna	Umjerena

*Kelly ima nizak rizik u pozitivnim igrama; u ovoj negativnoj igri to ne vrijedi.

6.6. Analiza ograničenog vremenskog horizonta

Realni igrači rijetko igraju 50 000 rundi. Simulacija je ponovljena s limitom od $N = 20$ rundi kako bi se prikazao ishod kratke sesije:

Table 6.4: Rezultati simulacije s limitom od 20 rundi, bankroll 100 000 €.

Strategija	Poč. bankroll	Konačni bankroll	Neto P&L	Ishod
Flat	100 000 €	99 913.33 €	−86.67 €	GUBITAK
Martingale	100 000 €	96 420.00 €	−3 580.00 €	GUBITAK
Anti-Martingale	100 000 €	99 931.67 €	−68.33 €	GUBITAK
Kelly	100 000 €	66 149.85 €	−33 850.15 €	GUBITAK

Posebno se ističe Kelly strategija koja u samo 20 rundi gubi 33 850 € — razlog je visoki početni ulog ($5\% \times 100\,000 = 5\,000$ € prve runde) u kombinaciji s negativnim RTP-om. Flat i Anti-Martingale bilježe minimalne gubitke od −87 € i −68 €.

6.7. Analiza ekstremnih događaja

Ekstreman događaj je situacija u kojoj igrač izvuče svih 10 adutnih karata (“crni labud”):

$$P(X = 10) = \frac{\binom{10}{10} \binom{30}{0}}{\binom{40}{10}} = \frac{1}{847\,660\,528} \approx 1.18 \times 10^{-9}$$

Table 6.5: Parametri ekstremnog događaja (10/10 aduta).

Parametar	Vrijednost
Vjerojatnost 10/10 aduta	1 u 847 760 528 rundi ($\approx 1.18 \times 10^{-9}$)
Pojavljivanja u 50 000 sim.	0 (statistički očekivano: 5.9×10^{-5})
Završni bodovi pri $X = 10$	220 bodova (prag: 120)
Isplatni faktor pri $X = 10$	$220/120 = 1.833\times$
Neto dobitak pri ulogu 1 000 €	+833.33 €
Neto dobitak pri $b_{max} = 500$ €	+416.67 €

Ni u 50 000 simuliranih rundi crni labud nije zabilježen, što potvrđuje teorijsku predikciju. Maksimalni isplatni faktor od $1.833\times$ je relativno nizak, što znači da čak i idealan scenarij donosi ograničen dobitak.

6.8. Casino optimizacija — preporuke upravi

Monte Carlo analiza s **500 replikacija** $\times$ **10 koraka** pokazuje prosječnu zaradu casina ovisno o dozvoljenom broju rundi:

Table 6.6: Prosječna zarada casina (€) po strategiji i limitu rundi (500 replikacija).

Limit rundi	Flat	Martingale	Kelly	Anti-Mart.
10	41.88	879.99	18 845.04	42.14
20	83.00	2 523.12	34 530.28	84.13
30	124.61	4 155.25	46 863.51	125.95
40	166.10	5 770.08	56 902.53	168.36
50	208.01	7 433.32	65 170.69	209.93
60	250.35	9 101.57	71 549.26	251.11
70	291.64	10 701.00	76 989.48	294.34
80	333.51	12 328.81	81 420.31	334.59
90	373.65	14 034.05	85 137.93	377.88
100	416.87	15 584.21	87 864.98	420.09

Ključni zaključci za upravljanje casinom:

- **Martingale igrači su najisplativiji:** Casino prosječno zarađuje 15 584 € od Martingale igrača u 100 rundi, naspram samo 417 € od Flat igrača.
- **Preporučeni limit:** 50–100 rundi po sesiji optimizira prihod casina uz prihvatljiv rizik.
- **Limit stola (b_{max}) je neophodan:** Bez gornjeg limita uloga, Martingale igrači postaju prevelik financijski rizik za likvidnost casina.

6.9. Casino risk management — stress test

Stress test proveden je na Martingale strategiji s **500 replikacija od 100 rundi**:

Table 6.7: Rezultati stress testa casino risk managementa.

Metrika	Vrijednost	Interpretacija
Maksimalna izloženost casina	1.67 €	Najveći isplaćeni dobitak u 500 replikacija
$P(\text{igrač dobije} > 50\% B)$	0.00%	Ni jedna replikacija nije dala “veliki dobitak”
Preporuka	SIGURNO	Trenutni limiti su sigurni za likvidnost

Pri zadanim parametrima ($b_{max} = 500$ €), casino nije u opasnosti od velikih isplata. Ograničenje stola djelotvorno sprječava eksponencijalni rast Martingale uloga.

7. Zaključak

Ovaj projekt demonstrira primjenu Monte Carlo metode za analizu stohastičkih sustava na primjeru briškula-based casino igre. Ključni doprinosi i zaključci su:

- **Matematička verifikacija:** Teorijski RTP od 58.33% i house edge od 41.67% potvrđeni su statističkom validacijom simulacije (χ^2 test, vizualna usporedba s hipergeometrijskom distribucijom). Model ispravno reproducira teorijsku distribuciju.
- **Jednakost strategija pred negativnom igrom:** Sve četiri strategije vode u bankrot u okviru simuliranog horizonta. Nijedna strategija klađenja ne može nadići matematičku prednost kuće — ovo je fundamentalni rezultat teorije igara.
- **Razlika u preživljavanju:** Flat bet preživljava najdulje (1 255 rundi), a Kelly kriterij najkraće (1 222 runde) pri dugim sesijama. Za kratke sesije (20 rundi), Flat i Anti-Martingale bilježe minimalne gubitke.
- **Preporuka za igrača:** Jedina racionalna strategija je igrati što manje rundi uz minimalni fiksni ulog — svaka dodatna runda statistički smanjuje kapital.
- **Preporuka za casino:** Martingale igrači donose najviši prihod (15 584 € u 100 rundi naspram 417 € od Flat igrača). Limit stola od 500 € je adekvatan za zaštitu likvidnosti casina.
- **Interaktivna aplikacija:** Razvijen je Shiny web dashboard koji omogućuje upravljačkom timu casina interaktivno ispitivanje različitih parametara bez poznavanja programiranja.

Projekt potvrđuje da Monte Carlo simulacija pruža moćan alat za donošenje informiranih poslovnih odluka u okruženjima s visokom stohastičnošću — od optimizacije casino operacija do upravljanja financijskim rizicima.

8. Popis literature

- [1] Ross, S.M. (2013) *Simulation*, 5th edn. Academic Press, Waltham, MA.
- [2] Robert, C.P. and Casella, G. (2004) *Monte Carlo Statistical Methods*, 2nd edn. Springer, New York.
- [3] Kelly, J.L. (1956) “A new interpretation of information rate”, *Bell System Technical Journal*, 35(4), pp. 917–926.
- [4] Law, A.M. (2015) *Simulation Modeling and Analysis*, 5th edn. McGraw-Hill, New York.
- [5] R Core Team (2024) *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. Dostupno na: <https://www.R-project.org/> (pristupljeno: 28. travnja 2026.).
- [6] Epstein, R.A. (2013) *The Theory of Gambling and Statistical Logic*, 2nd edn. Academic Press, Waltham, MA.
- [7] Thorp, E.O. (1962) *Beat the Dealer: A Winning Strategy for the Game of Twenty-One*. Blaisdell Publishing, New York.
- [8] Sheskin, D.J. (2011) *Handbook of Parametric and Nonparametric Statistical Procedures*, 5th edn. CRC Press, Boca Raton, FL.

A. Potpuni programski kod

A.1. Inicijalizacija i parametri sustava

Listing A.1: Blok 1: Postavke sustava i globalne varijable.

```
1 # --- 1. POSTAVKE SUSTAVA (Globalne varijable) ---
2 set.seed(42)
3 N_SIMS <- 50000
4 INIT_PTS <- 120
5 N_CARDS_DRAWN <- 10
6 SUITS <- 4
7 CARDS_PER_SUIT <- 10
8 START_BANKROLL <- 100000
9 DPI <- 300
10
11 # --- 1b. TUNABLE PARAMETRI STRATEGIJA ---
12 FLAT_BET <- 10 # Osnovni ulog za Flat/Martingale/Anti
13 # -Martingale
14 KELLY_FRACTION <- 0.05 # Kelly kriterij: udio bankrolla po
15 # rundi (5%)
16 MAX_BET <- 500 # Gornji limit uloga
17 N_LIMIT <- 20 # Broj rundi za analizu ogranicenog
18 # horizonta
19 LIMIT_STEPS <- seq(10, 100, by = 10)
20 N_CASINO_REPS <- 500 # Broj replikacija po koraku u casino
21 # optimizaciji
22 N_RISK_REPS <- 500 # Broj replikacija u stress testu
23 # rizika
24 BIG_WIN_THRESHOLD <- 0.5 # Prag "velikog dobitka" (50%
25 # bankrolla)
26
27 deck_suits <- rep(1:SUITS, each = CARDS_PER_SUIT)
```

A.2. Logika modela

Listing A.2: Blok 2: Funkcija jedne runde igre.

```
1 # --- 2. LOGIKA MODELA ---
2 play_round <- function(bet) {
3   briscola_suit <- sample(1:SUITS, 1)
4   shuffled <- sample(deck_suits)
5   hand <- shuffled[1:N_CARDS_DRAWN]
6
7   hits <- sum(hand == briscola_suit)
8   misses <- N_CARDS_DRAWN - hits
9   pts <- INIT_PTS + hits * 10 - misses * 10
10  mult <- pts / INIT_PTS
11  profit <- (mult - 1) * bet
12
13  return(list(hits = hits, profit = profit, mult = mult))
14 }
```

A.3. Simulacija strategija

Listing A.3: Blok 3: Monte Carlo simulator strategija.

```

1 # --- 3. SIMULACIJA STRATEGIJA ---
2 simulate_strategy <- function(strategy_name,
3                               n_sims = N_SIMS,
4                               flat_bet = FLAT_BET) {
5   bankroll <- numeric(n_sims + 1)
6   net_profit <- numeric(n_sims)
7   hits_vec <- numeric(n_sims)
8   bets_vec <- numeric(n_sims)
9
10  bankroll[1] <- START_BANKROLL
11  current_bet <- flat_bet
12
13  for (i in seq_len(n_sims)) {
14    bet <- switch(strategy_name,
15                 "Flat" = flat_bet,
16                 "Martingale" = current_bet,
17                 "Anti-Martingale" = current_bet,
18                 "Kelly" = max(1, bankroll[i] * KELLY_FRACTION)
19    )
20    bet <- min(bet, bankroll[i])
21
22    if (bankroll[i] <= 0) {
23      bankroll[(i + 1):(n_sims + 1)] <- 0
24      break
25    }
26
27    res <- play_round(bet)
28    bankroll[i+1] <- bankroll[i] + res$profit
29    net_profit[i] <- res$profit
30    hits_vec[i] <- res$hits
31    bets_vec[i] <- bet
32
33    if (strategy_name == "Martingale") {
34      current_bet <- if (res$profit < 0)
35                     min(current_bet * 2, MAX_BET) else flat_bet
36    } else if (strategy_name == "Anti-Martingale") {
37      current_bet <- if (res$profit > 0)
38                     min(current_bet * 2, MAX_BET) else flat_bet
39    }
40  }
41
42  return(list(name = strategy_name, bank = bankroll,
43             prof = net_profit, hits = hits_vec, bets = bets_vec))
44 }
45
46 # --- 4. IZVRSAVANJE ---
47 strategies <- c("Flat", "Martingale", "Anti-Martingale", "Kelly")
48 results <- lapply(strategies, simulate_strategy)
49 names(results) <- strategies

```

A.4. Analiza, validacija i casino optimizacija

Listing A.4: Blokovi 6–11: Validacija i casino optimizacija.

```

1 # --- 6. STATISTICKA VALIDACIJA ---
2 expected_mult <- (120 + 2.5 * 10 - 7.5 * 10) / 120
3 rtp_val      <- expected_mult * 100
4 cat(sprintf("Teorijski RTP: %.2f%% | House Edge: %.2f%%\n",
5             rtp_val, 100 - rtp_val))
6
7 # Chi-kvadrat test: simulacija vs. teorija
8 h_counts <- table(factor(results$Flat$hits, levels = 0:10))
9 theory   <- dhyper(0:10, 10, 30, 10)
10 chisq.test(h_counts, p = theory)
11
12 # Vizualizacija distribucije
13 tiff("01_Analiza_Modela_300dpi.tiff", width=2400, height=1800, res=
14     DPI)
15 par(mfrow = c(1, 2))
16 h_dist <- h_counts / sum(h_counts)
17 b <- barplot(h_dist,
18             main = "Distribucija aduta (Simulacija vs Teorija)",
19             col = "#4C72B0",
20             xlab = "Pogoci", ylab = "Vjerojatnost")
21 lines(x = b, y = theory, type = "b", pch = 18, col = "red", lwd = 2)
22 dev.off()
23
24 # --- 10. CASINO OPTIMIZACIJA ---
25 casino_izvjestaj <- data.frame()
26 for (limit in LIMIT_STEPS) {
27   avg_profits <- sapply(strategies, function(s) {
28     runs <- replicate(N_CASINO_REPS, {
29       sim <- simulate_strategy(s, n_sims = limit)
30       START_BANKROLL - tail(sim$bank, 1)
31     })
32     return(mean(runs))
33   })
34   casino_izvjestaj <- rbind(casino_izvjestaj, data.frame(
35     Maks_Rundi = limit,
36     Flat       = avg_profits["Flat"],
37     Martingale = avg_profits["Martingale"],
38     Kelly      = avg_profits["Kelly"],
39     Anti_Mart  = avg_profits["Anti-Martingale"]
40   ))
41 }
42
43 # --- 11. CASINO RISK MANAGEMENT ---
44 analyze_casino_risk <- function(n_reps = N_RISK_REPS) {
45   sims <- replicate(n_reps, {
46     res <- simulate_strategy("Martingale", n_sims = 100)
47     max_player_gain <- max(res$bank) - START_BANKROLL
48     big_win <- max_player_gain > (START_BANKROLL *
49       BIG_WIN_THRESHOLD)
50     return(c(max_gain = max_player_gain, win_flag = big_win))
51   })
52   max_exposure <- max(sims["max_gain", ])
53   win_rate_50pct <- mean(sims["win_flag", ]) * 100
54   cat(sprintf("Maks. izlozenost: %.2f EUR\n", max_exposure))
55   cat(sprintf("P(dobitak > 50%% bankrolla): %.2f%%\n", win_rate_50pct))
56   if (max_exposure > 500)
57     cat("PREPORUKA: UVESTI LIMIT STOLA!\n")

```

```
56     else
57         cat("Trenutni limiti su sigurni.\n")
58     }
59 analyze_casino_risk()
```