

Sveučilište Jurja Dobrile u Puli
Fakultet informatike u Puli

Modeliranje i simulacije
Projektni zadatak

**Monte Carlo simulacija strategija kladjenja
u pojednostavljenoj igri temeljenoj na briškuli**

Kolegij: Modeliranje i simulacije
Programski jezik: R
Vrsta simulacije: Monte Carlo simulacija
Student: Antonio Labinjan
Asistent: dr.sc. Robert Šajina
Nositelj: izv. prof. dr. sc. Darko Etinger
Akadska godina: 2025./2026.
Datum: Pula, 2026.

Contents

1	Opis sustava i područje primjene	3
1.1	Uvod	3
1.2	Opis sustava	3
1.3	Područje primjene	4
2	Vrsta simulacije i simulacijski jezik	5
2.1	Vrsta primijenjene simulacije	5
2.2	Simulacijski jezik	5
3	Podaci, varijable i distribucija	6
3.1	Opis podataka	6
3.2	Ulazne varijable	6
3.3	Slučajna varijabla	6
3.4	Izvedene varijable	7
4	Konceptualni model	8
4.1	Ideja modela	8
4.2	Strategije kladenja	9
5	Računalni model	10
5.1	Opis računalnog modela	10
5.2	Ulaz i izlaz modela	10
5.3	Validacija modela	10
6	Rezultati simulacije i tumačenje	12
6.1	Dugoročna simulacija	12
6.2	Kratki vremenski horizont	12
6.3	Ekstremni događaji	13
6.4	Casino perspektiva	13
6.5	Stress test rizika	13
7	Preporuke	15
7.1	Preporuke za igrača	15
7.2	Preporuke za organizatora igre	15
7.3	Ograničenja modela	15

8	Zaključak	17
8.1	Prilozi	18
8.1.1	Prilog A: Distribucija rezultata simulacije u odnosu na teoriju . . .	18
8.1.2	Prilog B: Kretanje bankrolla po strategijama	19
8.1.3	Prilog C: Distribucija uloga po strategijama	20
8.1.4	Prilog D: Profit casina po limitu rundi	21
8.1.5	Prilog E: Histogram profita po rundi za flat strategiju	22
8.1.6	Prilog F: Stres-test izloženosti casina	23
8.1.7	Zaključak priloga	23
9	Popis literature	25

1. Opis sustava i područje primjene

1.1. Uvod

U ovom projektu modelira se pojednostavljena kartaška igra inspirirana briškulom. Naglasak nije na potpunoj rekonstrukciji stvarne igre, nego na izradi simulacijskog modela kojim se može provjeriti kako se različite strategije klađenja ponašaju kroz velik broj ponovljenih rundi.

Sustav je zanimljiv za simulaciju zato što u sebi ima dva dosta jasna dijela. Prvi dio je slučajan: špil se miješa, adut se bira nasumično i igrač dobiva određeni broj karata. Drugi dio je deterministički: kada se karte jednom izvuku, rezultat se računa po točno zadanim pravilima. Zbog toga se igra može dobro opisati matematičkim modelom, ali je i dalje korisno napraviti računalnu simulaciju jer nas zanima ponašanje sustava kroz duži period, a ne samo jedna pojedinačna runda.

1.2. Opis sustava

Model koristi špil od 40 karata, podijeljen u četiri boje. Svaka boja ima 10 karata. Na početku svake runde jedna boja se nasumično odabire kao adut, odnosno briškula. Nakon toga se špil promiješa i igrač izvlači 10 karata bez vraćanja u špil.

Glavna vrijednost koja se prati je broj izvučenih aduta. Ako igrač izvuče više aduta, rezultat runde je bolji. Ako izvuče manje aduta, rezultat je lošiji. Na temelju toga računa se ispladni faktor i promjena bankrolla igrača.

Pojednostavljeno, jedna runda se odvija ovako:

1. odabire se adutna boja,
2. špil se nasumično miješa,
3. igrač izvlači 10 karata,
4. broji se koliko je među njima aduta,
5. računa se rezultat runde,
6. ažurira se stanje novca igrača.

Ovakav model nije zamišljen kao gotova casino igra, nego kao simulacijski primjer za analizu rizika, očekivanog gubitka i ponašanja strategija klađenja.

1.3. Područje primjene

Primjena ovog modela može se gledati iz dvije perspektive.

Iz perspektive igrača, simulacija pokazuje koliko dugo pojedina strategija može održavati kapital i postoji li način da se negativna matematička prednost igre kompenzira načinom kladenja. Drugim riječima, testira se popularna ideja da se “pametnom” strategijom uloga može pobijediti igra koja je u prosjeku nepovoljna.

Iz perspektive organizatora igre, model se može koristiti za procjenu očekivane zarade, rizika velikih isplata i postavljanje limita. U tom smislu izvještaj je oblikovan kao dokument koji bi mogao poslužiti upravi ili voditelju sustava kao brza procjena: kakva je igra, što simulacija pokazuje i koje se odluke mogu donijeti na temelju rezultata.

2. Vrsta simulacije i simulacijski jezik

2.1. Vrsta primijenjene simulacije

Za modeliranje je korištena Monte Carlo simulacija. To znači da se ista igra ponavlja velik broj puta, pri čemu se u svakoj rundi koriste nasumični ishodi. Nakon dovoljno velikog broja ponavljanja moguće je dobiti stabilnu procjenu prosječnog ponašanja sustava.

Simulacija je diskretna jer se stanje mijenja po rundama. Ne promatra se kontinuirano vrijeme, nego niz odvojenih događaja: runda 1, runda 2, runda 3 itd. Simulacija je stohastička jer ključni ishod runde, broj izvučenih aduta, ovisi o slučajnom miješanju i izvlačenju karata.

U osnovnoj analizi koristi se 50 000 simuliranih rundi po strategiji. Taj broj je dovoljno velik da se vidi dugoročni trend, a opet dovoljno praktičan da se simulacija može brzo izvršiti na običnom računalu.

2.2. Simulacijski jezik

Model je implementiran u programskom jeziku R. R je odabran jer je prirodan izbor za statističke simulacije, rad s distribucijama i izradu grafova. U projektu se koristi fiksirani seed, tako da se rezultati mogu reproducirati i provjeriti.

Table 2.1: Osnovne tehničke postavke simulacije.

Stavka	Opis
Programski jezik	R
Vrsta modela	Monte Carlo, diskretna stohastička simulacija
Broj rundi	50 000 po strategiji
Reproduktivnost	korišten je <code>set.seed(42)</code>
Vizualizacija	grafovi i tablice generirani iz R skripte/notebooka
Izlazni podaci	stanje bankrolla, profit/gubitak, broj pogodaka, usporedba strategija

3. Podaci, varijable i distribucija

3.1. Opis podataka

U ovom projektu nisu korišteni stvarni podaci iz casina ili stvarnih partija. Podaci su generirani simulacijom, na temelju unaprijed definiranih pravila igre. To je prikladno jer se radi o formalnom sustavu u kojem su pravila, veličina špila i način izvlačenja poznati.

Ulazni podaci su zapravo parametri modela: broj karata, broj boja, broj izvučenih karata, početni bankroll i pravila kladenja. Izlazni podaci nastaju izvođenjem simulacije i uključuju broj pogodaka, isplatni faktor, profit po rundi i kretanje bankrolla kroz vrijeme.

3.2. Ulazne varijable

Table 3.1: Glavni parametri modela.

Varijabla	Vrijednost	Značenje
Broj karata u špilu	40	Ukupan broj karata u modelu
Broj boja	4	Četiri skupine karata
Broj karata po boji	10	Svaka boja ima jednak broj karata
Broj izvučenih karata	10	Broj karata koje igrač dobiva u jednoj rundi
Početni bankroll	100 000 €	Početni kapital igrača u dugoj simulaciji
Osnovni ulog	10 €	Početni ulog kod fiksnih/progresivnih strategija
Maksimalni ulog	500 €	Limit koji sprječava neograničeno povećanje uloga
Kelly frakcija	5%	Udio bankrolla koji ulaže Kelly strategija

3.3. Slučajna varijabla

Najvažnija slučajna varijabla je broj adutnih karata u ruci igrača. Označena je s X . Budući da se karte izvlače bez vraćanja u špil, X slijedi hipergeometrijsku distribuciju:

$$X \sim \text{Hyper}(N = 40, K = 10, n = 10)$$

gdje je:

- $N = 40$ ukupan broj karata,
- $K = 10$ broj adutnih karata u špilu,
- $n = 10$ broj izvučenih karata.

Vjerojatnost da igrač izvuče točno x aduta računa se izrazom:

$$P(X = x) = \frac{\binom{10}{x} \binom{30}{10-x}}{\binom{40}{10}}, \quad x = 0, 1, \dots, 10.$$

Očekivani broj aduta u jednoj rundi iznosi:

$$E[X] = n \cdot \frac{K}{N} = 10 \cdot \frac{10}{40} = 2.5.$$

To znači da se u prosjeku očekuje između dvije i tri briškule u jednoj ruci. Upravo je to razlog zašto je igra za igrača nepovoljna: za pozitivniji ishod treba više pogodaka od onoga što se u prosjeku dobiva.

3.4. Izvedene varijable

Iz broja aduta računaju se bodovi, isplatni faktor i profit. U modelu svaki pogodak podiže rezultat, a svaka karta koja nije adut smanjuje rezultat.

$$\text{bodovi} = 120 + 10X - 10(10 - X)$$

$$\text{isplatni faktor} = \frac{\text{bodovi}}{120}$$

$$\text{profit} = (\text{isplatni faktor} - 1) \cdot \text{ulog}$$

Bankroll se nakon svake runde ažurira prema formuli:

$$B_{i+1} = B_i + \text{profit}_i.$$

4. Konceptualni model

4.1. Ideja modela

Konceptualni model prikazuje što se u sustavu događa bez ulaska u programski kod. Svaka runda ima isti tok: priprema runde, slučajno izvlačenje, izračun rezultata i ažuriranje bankrolla. Simulacija se ponavlja dok se ne dosegne zadani broj rundi ili dok igrač ne izgubi sav kapital.




Figure 4.1: Konceptualni tok jedne Monte Carlo simulacije.

4.2. Strategije kladenja

U simulaciji se uspoređuju četiri strategije. One ne mijenjaju pravila igre, nego samo način određivanja uloga.

Table 4.1: Strategije korištene u simulaciji.

Strategija	Opis
Flat	Igrač u svakoj rundi ulaže isti iznos. Strategija je jednostavna i najmanje agresivna.
Martingale	Nakon gubitka ulog se povećava, a nakon dobitka vraća se na početni iznos. Ideja je nadoknaditi prethodne gubitke, ali rizik brzo raste.
Anti-Martingale	Nakon dobitka ulog se povećava, a nakon gubitka vraća se na početni iznos. Strategija pokušava iskoristiti serije dobitaka.
Kelly	Ulog se računa kao postotak trenutnog bankrolla. U ovoj simulaciji korištena je frakcija od 5%.

Važno je naglasiti da nijedna strategija ne mijenja samu vjerojatnost dobitka. Strategije mogu promijeniti tempo gubitka, volatilnost i kratkoročni izgled rezultata, ali ne mogu ukloniti negativno očekivanje igre.

5. Računalni model

5.1. Opis računalnog modela

Računalni model implementiran je kao R skripta/notebook. Model je podijeljen na nekoliko logičkih dijelova: postavljanje parametara, simulaciju jedne runde, simulaciju više rundi za pojedinu strategiju, statističku validaciju i izradu grafova.

U pisanom dijelu nije cilj objašnjavati programski kod liniju po liniju. Bitno je da računalni model vjerno prati konceptualni model: karta se ne vraća u špil, adut se bira nasumično, a bankroll se nakon svake runde mijenja prema istim pravilima.

5.2. Ulaz i izlaz modela

Table 5.1: Ulazni i izlazni podaci računalnog modela.

Kategorija	Podaci
Ulazni podaci	Broj rundi, početni bankroll, osnovni ulog, maksimalni ulog, Kelly frakcija, odabrana strategija
Slučajni elementi	Odabir aduta, redoslijed karata u špil, broj aduta u ruci
Izlazni podaci	Broj pogodaka, profit po rundi, bankroll kroz vrijeme, trenutak bankrota, agregirani rezultati po strategiji
Vizualni izlazi	Graf distribucije aduta, usporedba simulacije s teorijom, grafovi kretanja kapitala i casino profita

5.3. Validacija modela

Model je provjeren usporedbom simulirane distribucije broja aduta s teorijskom hipergeometrijskom distribucijom. Ako simulacija radi ispravno, raspodjela dobivenih pogodaka trebala bi biti vrlo blizu teorijske raspodjele.

Osim toga, izračunat je teorijski RTP igre. Očekivani broj aduta je 2.5, pa očekivani ispladni faktor iznosi:

$$\frac{120 + 2.5 \cdot 10 - 7.5 \cdot 10}{120} = 0.5833.$$

Iz toga slijedi:

$$\text{RTP} = 58.33\%, \quad \text{House Edge} = 41.67\%.$$

Drugim riječima, igrač u prosjeku dobiva natrag samo 58.33% uloženog iznosa. To je jako nepovoljna igra za igrača, pa se već iz teorijskog dijela očekuje da će sve strategije dugoročno završiti loše.

6. Rezultati simulacije i tumačenje

6.1. Dugoročna simulacija

U dugoročnoj simulaciji svaka strategija testirana je kroz 50 000 rundi, uz početni bankroll od 100 000 €. Rezultati pokazuju da su sve strategije završile bankrotom. Razlike postoje samo u tome koliko dugo je pojedina strategija izdržala.

Table 6.1: Usporedba trajanja strategija prije bankrota.

Strategija	Preživljeno rundi	Tumačenje
Flat	1 255	Najdulje preživljavanje jer nema agresivnog povećavanja uloga.
Martingale	1 243	Nešto kraće od Flat strategije; progresija uloga ne spašava strategiju.
Anti-Martingale	1 234	Slično Flat strategiji, ali s nešto većom oscilacijom.
Kelly	1 222	Najkraće preživljavanje u ovoj simulaciji zbog većih relativnih uloga.

Glavni zaključak ovdje nije da je jedna strategija “pametna”, a druga “glupa”. Glavni zaključak je da negativno očekivanje pobjeđuje sve strategije ako se igra dovoljno dugo. Strategija može promijeniti oblik krivulje, ali ne i osnovnu matematiku igre.

6.2. Kratki vremenski horizont

Zasebno je promatran scenarij u kojem igrač ne igra dugo, nego stane nakon 20 rundi. Ovo je realističniji slučaj jer stvarni igrači često ne igraju tisuće rundi, nego kraću sesiju.

Table 6.2: Rezultati nakon 20 rundi.

Strategija	Konačni bankroll	Neto rezultat	Ishod
Flat	99 913.33 €	-86.67 €	Gubitak
Martingale	96 420.00 €	-3 580.00 €	Gubitak
Anti-Martingale	99 931.67 €	-68.33 €	Gubitak
Kelly	66 149.85 €	-33 850.15 €	Gubitak

U kratkoj sesiji Flat i Anti-Martingale gube najmanje. Kelly strategija se u ovom modelu pokazala izrazito agresivnom jer ulaže postotak velikog početnog bankrolla. Martingale također brzo može napraviti ozbiljan gubitak ako se pojavi niz loših ishoda.

6.3. Ekstremni događaji

Najbolji mogući ishod je da igrač izvuče svih 10 aduta. Taj događaj je moguć, ali je izuzetno rijedak. Vjerojatnost iznosi približno:

$$P(X = 10) = \frac{1}{\binom{40}{10}} \approx \frac{1}{847\,660\,528}.$$

U simulaciji od 50 000 rundi takav se događaj nije pojavio. To je očekivano, jer je vjerojatnost toliko mala da se radi o praktički ekstremnom događaju. U slučaju da se dogodi i da je ulog 1 000 €, neto dobitak bi bio 833.33 €.

Ovaj dio je koristan za razumijevanje razlike između “moguće” i “realno očekivano”. Teoretski se može dogoditi savršen ishod, ali na njemu se ne može graditi održiva strategija.

6.4. Casino perspektiva

Za upravo ili organizatora igre najvažnije pitanje nije samo može li igrač dobiti jednu rundu, nego koliki je očekivani profit kroz više rundi i koliko velik može biti rizik.

U analizi limita promatrano je koliko casino u prosjeku zarađuje ako ograniči broj rundi od 10 do 100. Za 100 rundi dobiveni su sljedeći prosječni rezultati:

Table 6.3: Očekivani profit casina nakon 100 rundi.

Strategija igrača	Profit casina	Komentar
Flat	416.87 €	Stabilan, ali relativno malen prihod.
Martingale	15 584.21 €	Najprofitabilniji scenarij za casino u ovoj simulaciji.
Anti-Martingale	420.09 €	Vrlo slično Flat strategiji.
Kelly	87 864.98 €	Ekstremno nepovoljan ishod za igrača zbog velikih uloga.

Rezultati pokazuju da agresivnije strategije ne predstavljaju nužno prijetnju casinu. Naprotiv, u ovom modelu često ubrzavaju gubitak igrača. Ipak, limit uloga ima smisla jer sprječava preveliku izloženost u rijetkim slučajevima kada igrač kratkoročno ima dobru seriju.

6.5. Stress test rizika

U stress testu Martingale strategije promatrala se najveća kratkoročna izloženost casina. Dobivena maksimalna izloženost iznosila je 1.67 €, a vjerojatnost da igrač osvoji više od 50% početnog bankrolla bila je 0.00%.

Ovakav rezultat ne znači da rizik ne postoji u apsolutnom smislu, nego da u zadanim

parametrima i uz postavljene limite nije zabilježen značajan kratkoročni rizik za casino. Drugim riječima, najveći problem ove igre nije to što casino previše riskira, nego to što je igra za igrača dugoročno izrazito nepovoljna.

7. Preporuke

7.1. Preporuke za igrača

Ako se sustav promatra iz perspektive igrača, rezultat je prilično jasan: najbolja zaštita od gubitka nije agresivna strategija, nego smanjenje broja rundi i smanjenje uloga. Flat i Anti-Martingale su u kratkom horizontu izgubile najmanje, ali ni one ne mijenjaju činjenicu da igra ima negativno očekivanje.

Preporuka za igrača bila bi:

- igrati mali broj rundi,
- koristiti minimalni ili fiksni ulog,
- izbjegavati agresivno povećavanje uloga,
- ne očekivati da strategija kladenja može pobijediti negativan RTP.

7.2. Preporuke za organizatora igre

Za organizatora igre model pokazuje da je sustav profitabilan, ali vrlo nepovoljan za igrača. To može biti dobro iz čisto financijske perspektive, ali loše iz perspektive atraktivnosti igre. Ako je cilj da igra bude održiva i zanimljiva, trebalo bi razmotriti blažu strukturu isplata.

Preporuke za casino ili organizatora:

- zadržati limit maksimalnog uloga jer smanjuje rizik velikih kratkoročnih isplata,
- pratiti agresivne strategije poput Martingalea, ali ih ne smatrati automatskom prijetnjom,
- razmotriti korekciju isplatnog sustava ako se želi bolji balans između zarade i zabave,
- koristiti simulaciju prije promjene pravila igre jer male promjene u isplati mogu jako promijeniti RTP.

7.3. Ograničenja modela

Model je namjerno pojednostavljen. Ne uključuje psihologiju igrača, promjenu ponašanja nakon većih dobitaka ili gubitaka, poreze, stvarne operativne troškove ni potpuno pravilo originalne briškule. Također, rezultati ovise o definiranim parametrima, posebno o isplatnom sustavu, početnom bankrollu i limitu uloga.

Unatoč tome, model je koristan jer jasno pokazuje glavnu stvar: ako je očekivana vrijednost igre negativna, dugoročna simulacija će to vrlo brzo pokazati.

8. Zaključak

Projekt je pokazao kako se Monte Carlo simulacija može koristiti za analizu jednostavne igre na sreću. Igra je modelirana preko špila od 40 karata, slučajnog odabira aduta i izvlačenja 10 karata bez vraćanja. Ključna slučajna varijabla, broj izvučenih aduta, opisana je hipergeometrijskom distribucijom.

Teorijski RTP iznosi 58.33%, dok je house edge 41.67%. Simulacija je potvrdila da je igra dugoročno izrazito nepovoljna za igrača. Sve promatrane strategije završile su bankrotom u dugom horizontu, a razlika među njima bila je uglavnom u brzini propadanja, ne u konačnom smjeru rezultata.

Najvažniji zaključak je da strategija klađenja ne može popraviti igru koja je matematički loše postavljena za igrača. Za organizatora igre to znači stabilan očekivani prihod, ali i potrebu da se pazi na atraktivnost igre. Za igrača to znači da je jedina realna obrana igrati kratko, s malim ulozima, i ne oslanjati se na progresivne sustave klađenja.

Zaključno, vizualizacije prikazane u priložima služe kao dodatna potvrda i proširenje numeričkih rezultata simulacije. One omogućuju jasniji uvid u raspodjelu ishoda, dinamiku promjene bankrolla, učestalost preživljenih rundi, strukturu uloga te potencijalnu izloženost casina u različitim uvjetima. Iako pojedine strategije mogu u određenim trenucima ostvariti povoljne rezultate, grafički prikazi pokazuju da dugoročni ishod ostaje snažno povezan s varijancom, ograničenjima početnog kapitala i pravilima igre. Zbog toga se može zaključiti da simulacijski pristup daje znatno potpuniju sliku od same teorijske analize, jer prikazuje ne samo očekivani rezultat, nego i ponašanje sustava u realističnijim i promjenjivim scenarijima.

8.1. Prilozi

Zbog preglednosti glavnog dijela rada, dodatne vizualizacije simulacijskih rezultata prikazane su u prilogima. Priloženi grafovi omogućuju detaljniju analizu raspodjele ishoda, ponašanja bankrolla, preživljenih rundi, strukture uloga, profita casina i stres-test scenarija.

8.1.1. Prilog A: Distribucija rezultata simulacije u odnosu na teoriju




Figure 8.1: Distribucija rezultata simulacije u odnosu na teorijski očekivani ishod.

Na slici se vidi da se simulirana distribucija broja izvučenih briškula gotovo u potpunosti poklapa s teorijskom hipergeometrijskom distribucijom. Najveća vjerojatnost pojavljuje se kod jedne izvučene briškule, zatim kod dvije, dok su ishodi s četiri ili pet briškula vrlo rijetki. Ovo pokazuje da simulacijski model ispravno reproducira očekivano ponašanje izvlačenja karata i da nema očitog odstupanja između simulacije i teorije.

8.1.2. Prilog B: Kretanje bankrolla po strategijama




Figure 8.2: Kretanje bankrolla kroz simulaciju za različite strategije.

Na slici se vidi da sve strategije započinju s bankrollom od 1000 eura, ali se bankroll vrlo brzo smanjuje kod svih promatranih pristupa. Martingale strategija najbrže dolazi do vrlo niske razine bankrolla jer agresivno povećava ulog nakon gubitka. Kelly strategija također pokazuje nagli pad, ali nešto postupniji od Martingalea. Flat i Anti-Martingale strategije padaju sporije i gotovo linearno, no također nakon nekoliko stotina rundi dolaze vrlo blizu nule. Graf jasno pokazuje da nijedna strategija u prikazanom scenariju ne održava početni kapital kroz dulji period.

8.1.3. Prilog C: Distribucija uloga po strategijama




Figure 8.3: Distribucija veličina uloga za različite strategije.

Na slici se vidi da su kod većine strategija ulogi najčešće koncentrirani pri manjim vrijednostima, ali se strategije jako razlikuju po ekstremnim vrijednostima. Flat strategija ima gotovo konstantne i vrlo male uloge, što je očekivano jer se ulog ne prilagođava rezultatu prethodnih rundi. Martingale strategija ima daleko najveće ekstreme, s ulozima koji dosežu i oko 500 eura, što pokazuje koliko brzo ova strategija može postati rizična nakon niza gubitaka. Anti-Martingale ima manje ekstreme od Martingalea, dok Kelly strategija pokazuje veći broj promjenjivih uloga, ali bez toliko ekstremnog rasta kao Martingale. Graf zato jasno pokazuje da Martingale nosi najveći rizik naglog povećanja izloženosti.

8.1.4. Prilog D: Profit casina po limitu rundi




Figure 8.4: Profit casina u ovisnosti o maksimalnom broju rundi.

Na slici se vidi da profit casina raste s povećanjem maksimalnog broja dozvoljenih rundi, ali intenzitet rasta nije jednak za sve strategije. Martingale strategija generira najveći profit casina i vrlo brzo dolazi blizu 1000 eura prosječnog profita, nakon čega se rast stabilizira. Kelly strategija također pokazuje kontinuiran rast profita casina, ali sporiji od Martingalea. Flat i Anti-Martingale strategije imaju znatno blaži rast, pri čemu je Anti-Martingale nešto iznad Flat strategije. Ovaj graf pokazuje da strategije koje agresivnije mijenjaju uloge mogu kratkoročno izgledati atraktivno igraču, ali dugoročno stvaraju veću prednost za kasino.

8.1.5. Prilog E: Histogram profita po rundi za flat strategiju




Figure 8.5: Histogram profita po rundi za flat betting strategiju.

Na slici se vidi da je kod Flat strategije većina profita po rundi koncentrirana oko nule, uz izražen vrh distribucije blizu prosječne vrijednosti. Prosječni profit po rundi iznosi približno -0.02 eura, što znači da je očekivani ishod za igrača blago negativan. Distribucija ima i negativne i pozitivne ishode, ali mali negativni prosjek pokazuje da se kroz velik broj ponavljanja prednost postupno pomiče prema casinu. Upravo je to tipično ponašanje strategije s konstantnim ulogom: nema velikih skokova u riziku, ali dugoročni očekivani rezultat ostaje nepovoljan za igrača.

8.1.6. Prilog F: Stres-test izloženosti casina




Figure 8.6: Stres-test izloženosti casina u ekstremnijim scenarijima.

Na slici se vidi da je maksimalna privremena izloženost casina u većini stres-test simulacija vrlo mala i koncentrirana blizu nule. Prosječna maksimalna izloženost iznosi oko 0.48 eura, dok najveći zabilježeni ekstrem doseže 15 eura. To znači da se u većini ponavljanja ne pojavljuje značajan privremeni dobitak igrača koji bi predstavljao ozbiljan rizik za kasino. Iako postoje rijetki ekstremniji slučajevi, oni su dovoljno rijetki i ograničeni da ukupna izloženost ostaje niska u odnosu na početni bankroll i očekivani profit casina.

8.1.7. Zaključak priloga

Priložene vizualizacije pokazuju da simulacijski model dobro prati teorijsku distribuciju izvlačenja briškula, što potvrđuje ispravnost osnovnog probabilističkog dijela simulacije. Analiza bankrolla zatim pokazuje da sve promatrane strategije dugoročno gube kapital, iako se razlikuju po brzini pada i razini rizika. Martingale je posebno rizičan jer vrlo brzo povećava uloge i zbog toga stvara najveće oscilacije, dok Flat strategija ima stabilnije ponašanje, ali i dalje blago negativan očekivani rezultat. Graf profita casina dodatno pokazuje da kasino dugoročno najviše profitira upravo protiv agresivnijih strategija, posebno Martingalea. Stres-test potvrđuje da su ekstremne privremene izloženosti casina rijetke i ograničene. Sveukupno, rezultati pokazuju da promjena strategije kladenja može

promijeniti dinamiku igre i razinu rizika, ali ne uklanja dugoročnu matematičku prednost casina.

9. Popis literature

- [1] Ross, S. M. (2013). *Simulation*. 5th edition. Academic Press.
- [2] Law, A. M. (2015). *Simulation Modeling and Analysis*. 5th edition. McGraw-Hill.
- [3] Robert, C. P. and Casella, G. (2004). *Monte Carlo Statistical Methods*. Springer.
- [4] Kelly, J. L. (1956). A New Interpretation of Information Rate. *Bell System Technical Journal*, 35(4), 917–926.
- [5] R Core Team. *R Documentation: Hypergeometric Distribution*. Dostupno u sklopu R dokumentacije za funkciju `dhyper()`.