

Sveučilište Jurja Dobrile u Puli
Fakultet informatike u Puli

MODELIRANJE I SIMULACIJE

Projektni zadatak

Monte Carlo simulacija strategija kladjenja u briškula-based igri na sreću

Kolegij: Modeliranje i simulacije

Mentor: dr.sc. Robert Sajina, asistent

Programski jezik: R

Vrsta simulacije: Monte Carlo (stohastička diskretna simulacija)

Akadska godina: 2025./2026.

Sadržaj

1	Opis sustava i područje primjene	3
1.1	Uvod	3
1.2	Opis igre i pravila modela	3
1.3	Područje primjene	3
2	Vrsta primijenjene simulacije i simulacijski jezik	4
2.1	Vrsta simulacije	4
2.2	Simulacijski jezik i okruženje	4
3	Opis prikupljenih podataka – izbor varijabli i distribucija	4
3.1	Ulazne varijable modela	4
3.2	Ključna slučajna varijabla i njezina distribucija	5
3.3	Izvedene varijable	6
4	Konceptualni model	6
4.1	Opis konceptualnog modela	6
4.2	Strategije kladenja	7
5	Računalni model	8
5.1	Arhitektura koda	8
5.2	Funkcija jedne runde	8
5.3	Monte Carlo simulator strategija	9
6	Opis simulacije, tumačenje rezultata i preporuke	10
6.1	Tijek simulacije	10
6.2	Teorijski RTP i house edge	10
6.3	Analiza strategija	11
6.3.1	Flat bet strategija	11
6.3.2	Martingale strategija	11
6.3.3	Anti-Martingale strategija	11
6.3.4	Kelly kriterij	11
6.4	Analiza ekstremnih događaja	11
6.5	Casino optimizacija – preporuke upravi	11
7	Popis literature	12
A	Potpuni programski kod	13
A.1	Inicijalizacija i parametri sustava	13
A.2	Logika modela	13

A.3	Simulacija strategija	14
A.4	Analiza, validacija i vizualizacija	15

1. Opis sustava i područje primjene

1.1. Uvod

Kartaška igra *Briškula* (tal. *Briscola*) jedna je od najrasprostranjenijih tradicijskih igara na Mediteranu, posebno popularna u Italiji i duž istočne jadranske obale. U kontekstu modeliranja i simulacija, Briškula predstavlja idealan predmet proučavanja jer kombinira elemente stohastičnosti (slučajno miješanje i izvlačenje karata) s determinističkim sustavom bodovanja, što omogućuje preciznu matematičku analizu i verifikaciju modela.

Ovaj projekt modelira **jednostavnu varijantu** igre u kojoj jedan igrač ulaže novac svaki krug, a konačni ishod ovisi o broju izvučenih adutnih karata (*briškula/aduta*). Sustav je opisan kao stohastički proces uzorkovanja bez ponavljanja iz konačne populacije karata jer se jednom izvučena karta ne vraća u špil.

1.2. Opis igre i pravila modela

Špil se sastoji od $N = 40$ karata podijeljenih ravnomjerno u $S = 4$ boje (vrste), pri čemu svaka boja sadrži $K = 10$ karata. Na početku svake runde:

1. Nasumično se bira jedna od četiri boje kao **adut** (briškula).
2. Špil se nasumično izmiješa (simulacija fizičkog miješanja).
3. Igrač izvlači $n = 10$ karata bez ponavljanja.
4. Broji se broj pogodaka X – karata koje pripadaju adutnoj boji.
5. Bodovni rezultat izračunava se prema formuli prikazanoj u poglavlju 5.

1.3. Područje primjene

Model ima dvostruku primjenu:

- **S perspektive igrača:** Analiza dugoročnih strategija klađenja i upravljanja kapitalom (*bankroll management*) – koja strategija maksimizira šansu preživljavanja i profita?
- **S perspektive casina/kockarnice:** Optimizacija limita rundi i procjena maksimalne financijske izloženosti pri različitim strategijama igrača (*risk management*).

Rezultati su primjenjivi u **teoriji igara**, **operacijskim istraživanjima**, **financijskom modeliranju** te obrazovnoj demonstraciji stohastičkih procesa.

2. Vrsta primijenjene simulacije i simulacijski jezik

2.1. Vrsta simulacije

Primijenjena metoda je **Monte Carlo simulacija** – klasa stohastičkih računalnih metoda koja koristi ponavljano nasumično uzorkovanje za dobivanje numeričkih rješenja problema koji bi analitički bili teško ili nemoguće rješivi. Ova vrsta simulacije spada u kategoriju **diskretnih stohastičkih simulacija** jer:

- Sustav mijenja stanje u diskretnim vremenskim koracima (runde igre).
- Slučajne varijable poprimaju diskretne vrijednosti (broj adutnih karata $X \in \{0, 1, \dots, 10\}$).
- Ne postoji kontinuirani tok vremena – svaka runda je neovisni eksperiment.

2.2. Simulacijski jezik i okruženje

Parametar	Vrijednost
Programski jezik	R (verzija ≥ 4.0)
IDE	RStudio / Jupyter Notebook (IRkernel)
Ključne funkcije	<code>sample()</code> , <code>replicate()</code> , <code>dhyper()</code>
Vizualizacija	Base R Graphics
Izvozni format	TIFF (300 DPI)

Odabir programskog jezika R opravdan je njegovom izvrsnom podrškom za statističke distribucije, vektorske operacije i reproduktivnost rezultata putem fiksiranog seeda (`set.seed(42)`).

3. Opis prikupljenih podataka – izbor varijabli i distribucija

3.1. Ulazne varijable modela

Sve ulazne veličine definirane su analitički na temelju pravila igre i nisu prikupljene empirijskim putem, što je karakteristično za formalne igre s poznatim pravilima. Tablica 1 prikazuje sve globalne parametre sustava.

Tablica 1: Globalni parametri simulacijskog modela.

Simbol	Naziv	Vrijednost	Opis
N	Veličina špila	40	Ukupan broj karata
S	Broj boja	4	Familije karata
K	Karata po boji	10	Karata svake familije
n	Broj izvučenih karata	10	Veličina ruke igrača
P_0	Početni bodovi	120	Bazni bodovni rezultat
B_0	Početni bankroll	10	Početni kapital igrača
b_{flat}	Osnovni ulog	10	Ulog za Flat strategiju
f	Kelly frakcija	0.05	5% bankrolla po rundi
b_{max}	Maksimalni ulog	500	Gornji limit uloga

3.2. Ključna slučajna varijabla i njezina distribucija

Centralna slučajna varijabla modela je **broj adutnih karata u ruci igrača**:

X = broj adutnih karata u izvučenih $n = 10$ karata

Ova varijabla slijedi **hipergeometrijsku distribuciju** jer se izvlačenje karata provodi bez povrata iz konačnog špila, što znači da svaki izvučeni adut smanjuje vjerojatnost izvlačenja sljedećeg:

$$X \sim \text{Hyper}(N, K, n) = \text{Hyper}(40, 10, 10)$$

Vjerojatnost da igrač izvuče točno x adutnih karata izračunava se pomoću kombinatornog pristupa gdje broj povoljnih ishoda (načini odabira aduta i ostalih karata) dijelimo s ukupnim brojem mogućih ruku:

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}} = \frac{\binom{10}{x} \binom{30}{10-x}}{\binom{40}{10}}, \quad x \in \{0, 1, \dots, 10\}$$

Parametri hipergeometrijske distribucije: Srednja vrijednost i mjera raspršenosti ključni su za razumijevanje stabilnosti modela:

$$E[X] = n \cdot \frac{K}{N} = 10 \cdot \frac{10}{40} = 2.5$$

$$\text{Var}(X) = n \cdot \frac{K}{N} \cdot \frac{N-K}{N} \cdot \frac{N-n}{N-1} = 10 \cdot \frac{10}{40} \cdot \frac{30}{40} \cdot \frac{30}{39} \approx 1.442$$

Očekivana vrijednost $E[X] = 2.5$ sugerira da će igrač u prosjeku imati između 2 i

3 aduta po dijeljenju. Varijanca od 1.442 (odnosno standardna devijacija $\sigma \approx 1.2$) ukazuje na relativno nisku volatilnost, što znači da su ekstremni rezultati (poput 0 ili 8 aduta) statistički rijetki.

3.3. Izvedene varijable

Kako bi se matematički model preveo u ekonomski sustav igre, definirane su sljedeće varijable:

- **Bodovni rezultat (pts):** Predstavlja linearnu transformaciju broja aduta. Svaki adut donosi bonus od 10 bodova, dok svaka karta koja nije adut $((n - X))$ nosi penalizaciju od 10 bodova, uz fiksni početni prag P_0 :

$$\text{pts} = P_0 + X \cdot 10 - (10 - X) \cdot 10$$

- **Isplatni faktor (mult):** Normalizirana vrijednost ostvarenih bodova u odnosu na početni prag. Ako je rezultat jednak pragu P_0 , faktor je 1 (break-even).
- **Neto profit po rundi:** Financijski ishod pojedine runde. Izračunava se kao umnožak uloga (*bet*) i razlike isplatnog faktora od jedinice.
- **Teorijski RTP (Return to Player):** Ključni indikator profitabilnosti igre. Uz pretpostavljeni prag $P_0 = 120$ i očekivanu vrijednost aduta $E[X] = 2.5$:


$$\text{mult}_{\text{teorijski}} = \frac{120 + 25 - 75}{120} = \frac{70}{120} \approx 0.5833$$

Rezultat pokazuje da je igra u trenutnim postavkama izrazito nepovoljna za igrača. **RTP od 58.33%** znači da igrač dugoročno gubi preko 40% svakog uloga, što rezultira visokim **House Edgeom od 41.67%**. Za postizanje balansa (RTP $\approx 95\text{--}98\%$), potrebno je korigirati vrijednosti bonusa ili sniziti fiksni prag P_0 .

4. Konceptualni model

4.1. Opis konceptualnog modela

Konceptualni model opisuje logiku i tok simulacije na razini apstrakcije, neovisno o implementaciji. Sustav se može promatrati kao **ciklički stohastički automat** s konačnim brojem stanja (Slika 1).



Slika 1: Dijagram toka konceptualnog modela Monte Carlo simulacije.

4.2. Strategije klađenja

Model implementira četiri strategije upravljanja kapitalom:

1. **Flat bet** – Ulog je fiksni i uvijek jednak b_{flat} . Najjednostavnija strategija bez prilagodbe.

2. **Martingale** – Progresivna negativna strategija: ulog se udvostručuje nakon svakog gubitka, a vraća na b_{flat} nakon dobitka:

$$b_{i+1} = \begin{cases} \min(2 \cdot b_i, b_{\max}) & \text{ako je runda } i \text{ gubitak} \\ b_{\text{flat}} & \text{inače} \end{cases}$$

3. **Anti-Martingale** – Zrcalna strategija: ulog se udvostručuje nakon dobitka:

$$b_{i+1} = \begin{cases} \min(2 \cdot b_i, b_{\max}) & \text{ako je runda } i \text{ dobitak} \\ b_{\text{flat}} & \text{inače} \end{cases}$$

4. **Kelly kriterij** – Optimalna strategija temeljena na teoriji informacija; ulog je fiksni postotak trenutnog bankrolla:

$$b_i = \max(1, f \cdot B_i), \quad f = 0.05$$

5. Računalni model

5.1. Arhitektura koda

Računalni model podijeljen je u modularne funkcije koje odgovaraju fazama simulacije:

Modul	Funkcija / Blok	Opis
Inicijalizacija	<code>set.seed(42)</code>	Fiksiranje pseudoslučajnosti
Logika igre	<code>play_round(bet)</code>	Simulacija jedne runde
Strategije	<code>simulate_strategy(...)</code>	Monte Carlo petlja
Analiza	Blokovi 4–8	Statistika i vizualizacija
Optimizacija	Blokovi 9–11	Casino risk management

5.2. Funkcija jedne runde

Listing 1: Računalni model jedne runde igre (R).

```

1 play_round <- function(bet) {
2   # Odabir aduta: diskretna uniformna distribucija na {1, 2, 3, 4}
3   briscola_suit <- sample(1:SUITS, 1)
4
5   # Mijesanje spila: nasumična permutacija 40 karata
6   shuffled <- sample(deck_suits)
7
8   # Izvlačenje prvih 10 karata (uzorkovanje bez ponavljanja)
9   hand <- shuffled[1:N_CARDS_DRAWN]
```

```

10
11 # Izracun pogodaka, bodova i profita
12 hits <- sum(hand == briscola_suit)
13 misses <- N_CARDS_DRAWN - hits
14 pts <- INIT_PTS + hits * 10 - misses * 10
15 mult <- pts / INIT_PTS
16 profit <- (mult - 1) * bet
17
18 return(list(hits = hits, profit = profit, mult = mult))
19 }

```

5.3. Monte Carlo simulator strategija

Listing 2: Iterativni Monte Carlo simulator (R).

```

1 simulate_strategy <- function(strategy_name,
2                               n_sims = N_SIMS,
3                               flat_bet = FLAT_BET) {
4   bankroll <- numeric(n_sims + 1)
5   bankroll[1] <- START_BANKROLL
6   current_bet <- flat_bet
7
8   for (i in seq_len(n_sims)) {
9     # Odabir uloga prema strategiji
10    bet <- switch(strategy_name,
11                  "Flat" = flat_bet,
12                  "Martingale" = current_bet,
13                  "Anti-Martingale" = current_bet,
14                  "Kelly" = max(1, bankroll[i] * KELLY_FRACTION)
15    )
16    bet <- min(bet, bankroll[i])
17
18    # Prijevremeni izlaz pri bankrotu
19    if (bankroll[i] <= 0) {
20      bankroll[(i+1):(n_sims+1)] <- 0
21      break
22    }
23
24    res <- play_round(bet)
25    bankroll[i+1] <- bankroll[i] + res$profit
26
27    # Azuriranje uloga za progresivne strategije
28    if (strategy_name == "Martingale") {
29      current_bet <- if (res$profit < 0)
30        min(current_bet * 2, MAX_BET) else flat_bet
31    } else if (strategy_name == "Anti-Martingale") {
32      current_bet <- if (res$profit > 0)

```

```

33         min(current_bet * 2, MAX_BET) else flat_bet
34     }
35 }
36 return(list(name = strategy_name, bank = bankroll, ...))
37 }

```

6. Opis simulacije, tumačenje rezultata i preporuke

6.1. Tijek simulacije

Simulacija se provodi u sljedećim fazama:

1. **Inicijalizacija** – postavljanje seeda, globalnih varijabli i špila.
2. **Izvođenje strategija** – svaka od četiri strategije pokreće se kroz N_SIMS iteracija.
3. **Statistička validacija** – usporedba simuliranih distribucija s teorijskim hipergeometrijskim.
4. **Analiza ekstremnih događaja** – procjena vjerojatnosti “crnog labuda”.
5. **Analiza limita rundi** – ispitivanje što se događa s ograničenim horizontom igre.
6. **Casino risk management** – stres test Martingale strategije s N_RISK_REPS = 500 replikacija.

6.2. Teorijski RTP i house edge

Ključni analitički rezultat modela je teorijski *Return to Player* (RTP):

$$E[\text{mult}] = \frac{120 + E[X] \cdot 10 - (10 - E[X]) \cdot 10}{120} = \frac{120 + 2.5 \cdot 10 - 7.5 \cdot 10}{120} = \frac{70}{120} \approx 0.5833$$

RTP = 58.33%	House Edge = 41.67%
--------------	---------------------

Ova visoka prednost kuće znači da je igra **matematički nepovoljna za igrača** na dugi rok, neovisno o odabranoj strategiji kladenja.

6.3. Analiza strategija

6.3.1. Flat bet strategija

Flat bet pruža **najstabilniji pad bankrolla** – jer se gubitak po rundi nikada ne povećava adaptivno, igrač najdulje “preživljava”. Međutim, i dobitak je maksimalno ograničen.

6.3.2. Martingale strategija

Martingale u teoriji “garantira” povrat nakon dovoljno dugog niza, ali u praksi:

- Eksponencijalni rast uloga brzo dostiže gornji limit $b_{\max} = 500$.
- Jedan duži niz gubitaka uzrokuje brz i trajan bankrot.
- **S perspektive casina:** najisplativija strategija – igrači koji je koriste prosječno gube najviše.

6.3.3. Anti-Martingale strategija

Udvostručivanjem uloga nakon dobitka, igrač “juri” serije. Profitabilna pri kratkim serijama sreće, ali nestabilna na dugom roku.

6.3.4. Kelly kriterij

Kelly strategija, teoretski optimalna za dugoročno preživljavanje, ovdje daje **spori ali stabilan pad** jer ulaže samo 5% trenutnog bankrolla. Nikad ne dostiže bankrot jednom udarcem, ali konvergira prema nuli.

6.4. Analiza ekstremnih događaja

Vjerojatnost da igrač izvuče svih 10 adutnih karata:

$$P(X = 10) = \frac{\binom{10}{10}\binom{30}{0}}{\binom{40}{10}} = \frac{1}{847,660,528} \approx 1.18 \times 10^{-9}$$

Ovo je statistički “crni labud” koji se u uobičajenom broju simulacijskih rundi ne pojavljuje.

6.5. Casino optimizacija – preporuke upravi

Na temelju casino risk management analize (500 replikacija $\times$ 10 koraka):

1. **Martingale igrači** donose casinu najveći prosječni prihod po seji – ova strategija treba biti *dopuštena*.

2. **Ograničenje stola** je nužno: bez gornjeg limita uloga, rijetki ali veliki dobitci Martingale igrača mogu ugroziti likvidnost.
3. **Preporučeni limit rundi:** 50–100 rundi po seji optimizira prihod casina uz prihvatljiv rizik.
4. **S perspektive igrača:** optimalna strategija je *igrati što manje rundi i nadati se ranoj sreći* – svaka dodatna runda statistički smanjuje kapital.

Tablica 2: Usporedna analiza strategija – ključne karakteristike.

Karakteristika	Flat	Martingale	Anti-Mart.	Kelly
Volatilnost bankrolla	Niska	Visoka	Umjerena	Niska
Rizik bankrota	Srednji	Visok	Srednji	Nizak
Korist za casino	Umjerena	Visoka	Umjerena	Niska
Dugoročna preživljavanja	Dobro	Loše	Umjereno	Dobro
Kompleksnost	Trivijalna	Jednostavna	Jednostavna	Umjerena

7. Popis literature

- [1] Ross, S.M. (2013) *Simulation*, 5th edn. Academic Press, Waltham, MA.
- [2] Robert, C.P. and Casella, G. (2004) *Monte Carlo Statistical Methods*, 2nd edn. Springer, New York.
- [3] Kelly, J.L. (1956) ‘A new interpretation of information rate’, *Bell System Technical Journal*, 35(4), pp. 917–926.
- [4] Law, A.M. (2015) *Simulation Modeling and Analysis*, 5th edn. McGraw-Hill, New York.
- [5] R Core Team (2024) *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. Dostupno na: <https://www.R-project.org/> (pristupljeno: 28. travnja 2026.).
- [6] Epstein, R.A. (2013) *The Theory of Gambling and Statistical Logic*, 2nd edn. Academic Press, Waltham, MA.
- [7] Thorp, E.O. (1962) *Beat the Dealer: A Winning Strategy for the Game of Twenty-One*. Blaisdell Publishing, New York.
- [8] Sheskin, D.J. (2011) *Handbook of Parametric and Nonparametric Statistical Procedures*, 5th edn. CRC Press, Boca Raton, FL.

A. Potpuni programski kod

A.1. Inicijalizacija i parametri sustava

Listing 3: Blok 1: Postavke sustava i globalne varijable.

```

1 # --- 1. POSTAVKE SUSTAVA (Globalne varijable) ---
2 set.seed(42)
3 N_SIMS <- 5
4 INIT_PTS <- 120
5 N_CARDS_DRAWN <- 10
6 SUITS <- 4
7 CARDS_PER_SUIT <- 10
8 START_BANKROLL <- 10
9 DPI <- 300
10
11 # --- 1b. TUNABLE PARAMETRI STRATEGIJA ---
12 FLAT_BET <- 10 # Osnovni ulog
13 KELLY_FRACTION <- 0.05 # Kelly: 5% bankrolla
14 MAX_BET <- 500 # Gornji limit uloga
15 N_LIMIT <- 20 # Limit rundi za horizont analizu
16 LIMIT_STEPS <- seq(10, 100, by = 10)
17 N_CASINO_REPS <- 500 # Replikacije za casino optimizaciju
18 N_RISK_REPS <- 500 # Replikacije za stress test
19 BIG_WIN_THRESHOLD <- 0.5 # Prag "velikog dobitka" (50%
    bankrolla)
20
21 deck_suits <- rep(1:SUITS, each = CARDS_PER_SUIT)

```

A.2. Logika modela

Listing 4: Blok 2: Funkcija jedne runde igre.

```

1 # --- 2. LOGIKA MODELA ---
2 play_round <- function(bet) {
3   briscola_suit <- sample(1:SUITS, 1)
4   shuffled <- sample(deck_suits)
5   hand <- shuffled[1:N_CARDS_DRAWN]
6
7   hits <- sum(hand == briscola_suit)
8   misses <- N_CARDS_DRAWN - hits
9   pts <- INIT_PTS + hits * 10 - misses * 10
10  mult <- pts / INIT_PTS
11  profit <- (mult - 1) * bet
12
13  return(list(hits = hits, profit = profit, mult = mult))
14 }

```

A.3. Simulacija strategija

Listing 5: Blok 3: Monte Carlo simulator strategija.

```

1  # --- 3. SIMULACIJA STRATEGIJA ---
2  simulate_strategy <- function(strategy_name,
3                                n_sims    = N_SIMS,
4                                flat_bet  = FLAT_BET) {
5
6    bankroll    <- numeric(n_sims + 1)
7    net_profit  <- numeric(n_sims)
8    hits_vec    <- numeric(n_sims)
9    bets_vec    <- numeric(n_sims)
10
11    bankroll[1] <- START_BANKROLL
12    current_bet <- flat_bet
13
14    for (i in seq_len(n_sims)) {
15      bet <- switch(strategy_name,
16                    "Flat"           = flat_bet,
17                    "Martingale"     = current_bet,
18                    "Anti-Martingale" = current_bet,
19                    "Kelly"          = max(1, bankroll[i] * KELLY_FRACTION)
20      )
21      bet <- min(bet, bankroll[i])
22
23      if (bankroll[i] <= 0) {
24        bankroll[(i+1):(n_sims+1)] <- 0
25        break
26      }
27
28      res <- play_round(bet)
29      bankroll[i+1] <- bankroll[i] + res$profit
30      net_profit[i] <- res$profit
31      hits_vec[i]   <- res$hits
32      bets_vec[i]   <- bet
33
34      if (strategy_name == "Martingale") {
35        current_bet <- if (res$profit < 0)
36          min(current_bet * 2, MAX_BET) else flat_bet
37      } else if (strategy_name == "Anti-Martingale") {
38        current_bet <- if (res$profit > 0)
39          min(current_bet * 2, MAX_BET) else flat_bet
40      }
41    }
42
43    return(list(name = strategy_name, bank = bankroll,
44               prof = net_profit, hits = hits_vec, bets = bets_vec))
45  }

```

A.4. Analiza, validacija i vizualizacija

Listing 6: Blokovi 4–11: Analiza i casino optimizacija (sažetak).

```

1 # --- 4. IZVRSAVANJE ---
2 strategies <- c("Flat", "Martingale", "Anti-Martingale", "Kelly")
3 results    <- lapply(strategies, simulate_strategy)
4 names(results) <- strategies
5
6 # --- 6. STATISTICKA VALIDACIJA ---
7 expected_mult <- (120 + 2.5 * 10 - 7.5 * 10) / 120
8 rtp_val       <- expected_mult * 100
9 cat(sprintf("Teorijski RTP: %.2f%% | House Edge: %.2f%%\n",
10            rtp_val, 100 - rtp_val))
11
12 # Vizualizacija: simulacija vs teorija
13 tiff("01_Analiza_Modela_300dpi.tiff", width=2400, height=1800, res=DPI
14     )
15 par(mfrow = c(1, 2))
16 h_counts <- table(factor(results$Flat$hits, levels=0:10))
17 h_dist   <- h_counts / sum(h_counts)
18 theory    <- dhyper(0:10, 10, 30, 10)
19 b <- barplot(h_dist, main="Distribucija aduta (Simulacija vs Teorija)"
20             ,
21             col="#4C72B0", xlab="Pogoci", ylab="Vjerojatnost")
22 lines(x=b, y=theory, type="b", pch=18, col="red", lwd=2)
23 dev.off()
24
25 # --- 11. CASINO RISK MANAGEMENT ---
26 analyze_casino_risk <- function(n_reps = N_RISK_REPS) {
27   sims <- replicate(n_reps, {
28     res <- simulate_strategy("Martingale", n_sims = 100)
29     max_player_gain <- max(res$bank) - START_BANKROLL
30     big_win <- max_player_gain > (START_BANKROLL * BIG_WIN_THRESHOLD)
31     return(c(max_gain = max_player_gain, win_flag = big_win))
32   })
33   max_exposure <- max(sims["max_gain", ])
34   win_rate_50pct <- mean(sims["win_flag", ]) * 100
35   cat(sprintf("Maks. izlozenost: %.2f EUR\n", max_exposure))
36   cat(sprintf("P(dobitak > 50%% bankrolla): %.2f%%\n", win_rate_50pct)
37       )
38   if (max_exposure > 500)
39     cat("PREPORUKA: UVESTI LIMIT STOLA!\n")
40   else
41     cat("Trenutni limiti su sigurni.\n")
42 }
43 analyze_casino_risk()

```